

足球赛事舆情风险的龙虾智能体构建

技术路线研究报告（一期）


执行摘要

本报告在前期调研与快速原型验证（MVP）的基础上，系统梳理了“龙虾智能体”从数据采集到风险预警的完整技术路线。与初期预研相比，实际验证发现：基于云端 OpenClaw（龙虾）的多智能体方案在上下文控制、大规模循环采集上存在结构性瓶颈，难以满足生产级稳定性要求。因此，本项目将感知层迁移至本地 Playwright 浏览器自动化框架，将研判与预警层拆分为独立的 Python 服务，并引入 DeepSeek 大模型 API 作为推理增强引擎，形成“本地采集 + 分层研判 + LLM 综合预警”的混合架构。

第一节 总体技术路线概述

1.1 核心架构

本项目采用“三层分离、逐步集成”的模块化架构，严格对应申请书中“数据层—模型层—应用层”的技术路线图：



1.2 技术路线演进说明

初期预研曾考虑基于腾讯云 OpenClaw（ArkClaw / Lighthouse 镜像）构建全栈方案，但在 MVP 验证中发现以下瓶颈：

瓶颈	具体表现	应对策略
上下文膨胀	OpenClaw 单轮对话处理超过 15 条微博即触发模型截断	放弃 OpenClaw 做采集循环，改用 Playwright 脚本
Cookie 隔离	OpenClaw 浏览器环境无法向宿主机导出真实 Cookie	本地 Playwright 直接管理 storage_state
元素漂移	LLM 对微博动态 DOM 的定位不稳定，频繁超时	固定选择器 + 多轮容错代码化
成本不可控	云端 SaaS 月租 + Token 双重计费，3000 元预算紧张	本地部署 + DeepSeek API 按量计费

因此，最终路线调整为：本地 Playwright 负责高稳定性采集，Python 分层服务负责结构化分析，DeepSeek API 仅用于高层语义推理，兼顾稳定性、成本与智能性。

第二节 感知层：足球赛事舆情信息获取

2.1 方案一：爬虫采集（本项目采用）

技术实现

采用 Playwright（Microsoft 官方浏览器自动化框架）驱动本地 Chromium/Chrome，直接操作微博搜索页（`https://s.weibo.com/weibo`）。

核心流程：

- 1. 登录态管理：首次通过 `login.py` 弹出浏览器窗口扫码登录，保存 `storage\_state.json`；后续采集直接加载，绕过重复登录风控。
- 2. 反检测对抗：启动参数注入 `--disable-blink-features=AutomationControlled`，并覆盖 `navigator.webdriver`、`plugins`、`languages` 等指纹。
- 3. 动态渲染：微博搜索页为 SSR + CSR 混合架构，Playwright 的 `wait\_until="domcontentloaded"` 配合 5 秒显式等待，确保 JavaScript 渲染完成。
- 4. 内容展开：三轮循环点击 `text=展开 / 展开全文`，解决微博折叠机制。
- 5. 时间标准化：解析 `""32 秒前""`、`""5 分钟前""`、`""今天 19:33""` 等相对时间，转换为绝对时间，供时序分析使用。

6. 输出格式：结构化 JSON，字段包括 `mid`、`content`、`time`、`username`、`link`、`crawl\_time`。

数据导入下游：

采集结果以文件形式写入 `/data/{keyword}\_{date}\_{count}条.json`。研判层通过文件系统直接读取，无需中间件或数据库，降低架构复杂度。

优势与局限

- 优势：真人化程度高（真实浏览器、真实 Cookie、真实鼠标轨迹），反爬通过率显著高于 `requests/Scrapy`；可处理动态渲染与复杂交互（展开、翻页）。
- 局限：依赖本地图形环境（首次登录需 `headless=False`）；大规模并发需配合代理池（当前 MVP 为单线程）。

2.2 方案二：现有 API 采集

调研结论

市面主流微博数据 API 包括：

- 微博官方 API V2：需企业认证，足球赛事类搜索权限受限，且 2024 年后大幅收紧读取频次，不适合学术项目。
- 第三方舆情 SaaS（如清博、知微）：数据完整性好，但按关键词/时间区间计费，单条赛事采集成本约 0.1–0.3 元，150 条样本即 15–45 元，且无法自定义清洗规则与情感词典，与项目“基于词典法的情感分析”创新点冲突。
- 开源 weibo-crawler 等封装库：本质仍为爬虫，封装了请求签名，但微博反爬升级后失效频率高。

对比与推荐

维度	方案一 Playwright	方案二 第三方 API
稳定性	高（真人浏览器）	中（依赖平台政策）
成本	仅 API 调用费（DeepSeek ≈ ¥0.005/次）	¥0.1–0.3/条 + 订阅费
数据可控性	高（自定义字段、清洗、去重）	低（固定字段）
情感分析适配	高（直接对接自研词典）	低（需二次转换）
合规风险	低（公开搜索页数据）	中（依赖第三方授权）

推荐方案：方案一（Playwright 本地采集）作为主力感知层。对于后续需要历史数据补录的场景，可酌情引入第三方 API 作为辅助。

第三节 研判与预警层：龙虾智能体构建

3.1 多智能体角色定义与协同

本项目严格遵循申请书“感知—研判—预警”三智能体架构，但在实现上将其映射为三个独立的 Python 服务模块，通过数据文件流转实现协同：

智能体	对应模块	输入	输出	核心职责
感知智能体	weibo_collector.py	关键词、日期范围	原始 JSON	真人化采集、时间标准化、反检测
研判智能体	analyzer.py	原始 JSON	judgment_*.json	主题聚类、情感量化、时序演化、传播特征
预警智能体	warner.py	judgment_*.json	warning_*.json	五维评分、风险定级、LLM 综合建议

协同工作流：

1. 用户通过 `launcher.py` 一键触发，或命令行顺序执行；
2. 各模块间不共享内存，只传递标准化 JSON，确保单模块故障不影响上下游；
3. 每个模块输出包含 `generated\_at` 时间戳与 `meta` 元数据，便于审计与回溯。

3.2 研判层：五维分析模型

摒弃了过去 SITP 研究中“主题-情感-用户”三维框架中用户人口画像维度（因为该维度对实时预警指导意义有限），新增时序演化与传播特征维度，形成五维研判框架：

1. 主题维度：TF-IDF 提取关键词 + 规则种子词聚类（赛事战况、球员/教练、裁判/VAR、赛事组织、青训/未来、地域/球迷文化、商业/品牌）。
2. 情感维度：继承前期研究成果，采用基于词典的情感打分机制，构建 5 大类 11 子词典（正面、负面、否定词、6 级程度副词、情绪标点）。通过 jieba 分词 + 窗口内否定词奇偶判定 + 程度副词加权，计算句级正负均值。
3. 时序维度：按小时分桶统计负面率，识别突变点（spike）与趋势加速度（acceleration）。这是预警层最关键的输入信号。
4. 传播维度：通过文本特征推导行为画像——意见领袖候选（长文 + 分析性词汇）、情绪传染度（感叹号/问号密度）、讨论集中度（Top3 用户发帖占比）。
5. 风险因子维度：敏感词密度、德比/对立情绪密度、历史包袱密度（“又输了”、“总是黑哨”等时间副词 + 负面情感组合）。

3.3 预警层：五维评分卡 + LLM 推理

规则引擎（可解释、可审计）：

- 情感维度：0–30 分（负面率 $\times$ 20 + 强度 $\times$ 3 + 极端负面密度 $\times$ 10）
- 时序维度：0–25 分（突变时段数量 $\times$ 7 + 加速度 $\times$ 30）
- 主题维度：0–20 分（高风险议题占比）
- 传播维度：0–15 分（情绪标点密度 + 集中度）
- 敏感因子：0–10 分（敏感词/对立/历史包袱密度）

风险定级：

- 极高： ≥ 60 分
- 高：40–59 分
- 中：20–39 分
- 低： < 20 分

LLM 综合推理：

- 仅调用 DeepSeek API 做高层语义生成，输入为已确定的五维评分与触发规则，输出为自然语言简报（summary、key_risks、pr_suggestions、monitor_focus）。
- 不将原始微博全文直接送入 LLM，避免 Token 爆炸与成本失控。单次研判 LLM 调用成本约 **¥0.005–0.01**。

3.4 可解释性与可视化

- 可解释性：预警 JSON 中保留 `dimension\_scores`（各维度得分）、`triggered\_rules`（触发规则列表），任何风险定级均可追溯至具体统计指标。
- 可视化：`report\_generator.py` 读取 judgment + warning，生成单页 HTML 报告，内嵌 matplotlib 饼图（议题分布、情感分布）与折线图（负面率时序演化）。

第四节 应用层与系统集成

4.1 当前 MVP 形态

后端：无（本地脚本直接读写文件）。

前端：浏览器打开生成的 HTML 报告。

调度：`launcher.py` 一键顺序执行四步（采集 $\rightarrow$ 研判 $\rightarrow$ 预警 $\rightarrow$ 报告）。

4.2 二期扩展路径

模块	当前 MVP	二期目标
后端服务	本地脚本	FastAPI + Uvicorn，提供 /generate_report REST 接口
前端演示	静态 HTML	Streamlit / Gradio 快速 Web 界面，支持输入参数与实时刷新
移动端	无	Flutter 调用 FastAPI，实现“轻量化交互工具”
存储	本地 JSON	MongoDB / SQLite，支持历史数据查询与对比分析

第五节 导师委托：足协任务调研结论（OpenClaw 商用与替代方案）

受导师委托，对“商用 OpenClaw 及替代品”进行了专项调研，核心结论如下：

1. 商用 OpenClaw 本质

互联网大厂（字节、腾讯、华为）提供的“成熟商业化 OpenClaw”并非独立软件销售，而是**开源 OpenClaw 预部署镜像 + 云服务器托管**的捆绑服务。用户支付的是服务器月租（9.9–200 元/月，视配置），预购 Token 在控制台填入即可使用。

2. 主要厂商报价（Token 已预购场景，仅计算托管费）

厂商	产品	最低月租	特点
字节火山引擎	ArkClaw	≈ 50 元/月	官方 SaaS，零配置，支持多 Agent
腾讯云	Lighthouse + OpenClaw 镜像	≈ 58 元/月（2 核 2G）	一键部署，预装环境，支持微信/QQ 接入
华为云	Flexus + OpenClaw	≈ 85–155 元/月	企业级稳定运行，附资源规划示例

3. 对本项目的适用性评估

OpenClaw 可作为辅助触发器或人机交互界面，但不应作为感知层核心引擎。本项目当前采用“Playwright 采集 + Python 分析 + DeepSeek 推理”的混合路线，在稳定性与成本上均优于纯 OpenClaw 方案。

第六章 风险评估与应对

风险	可能性	影响	应对措施
微博反爬升级	中	高	已预留代理池预算；Playwright 可快速切换 User-Agent 与指纹
登录态过期	高	中	storage_state 有效期 1-7 天，设置自动检测与提醒机制
LLM API 限流	低	中	DeepSeek 并发限制较宽松；预留重试与降级规则
情感词典覆盖不足	中	高	建立迭代机制，每轮采集后人工抽查 10 条，补充漏检词
团队成员技术栈差异	中	中	统一使用 Python + Playwright，文档化部署步骤，降低协作门槛

结论与下一步工作

- 技术路线确认：本项目采用“本地 Playwright 采集 + 多维研判模型 + DeepSeek LLM 预警 + HTML 可视化”的混合架构，已跑通端到端 MVP，证明可行。
- 与申请书一致性：严格遵循“模块化开发、逐步集成”原则，感知/研判/预警三层解耦，符合“龙虾智能体”的多智能体协同设计理念。
- 下一步工作：
 - 情感词典迭代与阈值调优（解决当前负面漏判问题）；
 - 部署至腾讯云，实现定时采集与 Web 服务化；
 - 开发 Flutter 前端，完成“轻量化交互工具”目标。

附录：核心代码清单（MVP）

文件	职责
collector/login.py	扫码登录，持久化 storage_state
collector/weibo_collector.py	感知层：Playwright 采集
collector/sentiment_engine.py	情感分析引擎（词典法）

collector/analyzer.py	研判层： 五维分析
collector/warner.py	预警层： 五维评分 + LLM
collector/report_generator.py	可视化报告生成
launcher.py	一键调度脚本